目标客户甄选模型

——logistic 回归客户甄选模型

一、 业务理解

面对公司不断积累的客户，“哪些客户是我们的目标客户？如何在既定的成本下选择最优的联系客户群体以实现效益的最大化？”成了当前业务发展中急需解决的一大问题。基于对问题的理解利用适当的数据分析方法，构建目标客户甄选模型，寻找最具成交可能性的客户，以供客户分配联系时的甄选，寻求效益的最大化。

二、数据理解

基于对业务问题的理解，进一步结合公司目前的数据情况，可采用数据挖掘中的 LOGISTIC 回归模型来解决实际的客户识别甄选问题。

2.1 LOGISTIC 回归模型简介

LOGISTIC 回归是一种特殊的回归模型，主要应用在研究某些现象发生的概率 P 与哪些因素有关，与线性回归模型不同，由于实际问题的复杂性，实际上也很难用线性模型来描述概率 P 与变量的关系。 Logistic 回归通过较为充分的考虑各方面因素的关系，来得出概率值 P 。由于概率值 P∈[0,1],若以 0.5 为分界点，则每个概率值都能划分到分界点的两侧中，实际中常运用二分类的 logistic 回归描述诸如客户是否会定购某种业务（即定购抑或不定购），或者客户最终是否成交（成交或不成交）等等。由于现实中存在大量类似的问题，LOGISITC 回归被广泛运用以解决所谓的分类问题。

评分结果的最终公式表达如下：

$$P = \frac{\exp(\alpha)}{1+\exp(\alpha)}$$

其中， $\alpha = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$ 。

$x_0, x_1, \cdots, x_k$ 为相应的变量，代表实际问题中的某一些因素。$\beta_0, \beta_1, \cdots, \beta_k$ 为对应

变量的系数，由公式得到的值 P 代表综合各因素后的事件概率值。所以，接下来进一步应从各公司数据库各数据表中整理合适的 $x_0, x_1, \cdots, x_k$ 各变量供模型的搭建。

2.2 数据字段选取

基于业务理解以及现有数据情况，选取以下变量作为构建模型的基础变量。

表 2.1 数据字段选取与定义

变量名	定义说明
客户编号	客户识别标记
客户等级	客户等级属于分类变量需做相应的转换处理，以符合 logistic 模型字段要求
客户状态	同上，需做相应的数据处理，按公司的业务情况常将客户等级与客户状态结合起来考虑，在后续建模时将两个字段合并转化成新的字段
分配状态	客户是否分配，已分配标记为 1，未分配标记为 0
城市→城市得分	鉴于城市较多，引入太多分类的城市将使得模型结果较为复杂且不易解读，事先按历史成交量对城市做排名，并依据排名得分做相应的替换处理
来源→来源得分	同上，客户存在有较多来源，引入太多分类变量将使得模型结果较为复杂且不易解读，在建模前先对不同来源组合进行评分，替代并简化来源变量。注意：客户来源具体到来源网站，并且对于不同年份的同一个来源，视为相同的来源，记客户有该类型来源，例如客户来源中有 2009 年中小企业网、2010 年中小企业网，记客户有中小企业网的来源，数据处理时需做相应的去重复处理
行业→行业得分	客户行业，同上，一家客户存在较多行业，需简化变量来简化模型，所以事先也需对不同行业成交率做评估，用综合得分来替代行业变量
联系次数	业务员主动联系客户次数，统计包括电话、邮件、会面、聊天工具类型的联系
最近一次联系时长间隔	计算每家客户最近一次联系时间与所选时间的联系时长间隔
来源次数	客户来源网站次数，同一网站的来源只按一次统计
最近一次来源时长间隔	计算每家客户最近一次来源时间与所选时间的来源时长间隔
网络咨询次数	客户主动进行网络咨询的次数
国外会刊次数	参与国外展会次数
被分配次数	一家客户历史被分配次数

灭失销售进程次数	客户产生进入销售进程后灭失需求、意向、报名、成交等销售状态的次数
是否外贸数据客户	标记客户是否有外贸出口金额，有即标记 1，无标记 0
2012 年外贸出口金额	客户 2012 年外贸出口金额
2011 年外贸出口金额	客户 2011 年外贸出口金额
2010 年外贸出口金额	客户 2010 年外贸出口金额
是否成交	标记客户是否成交，成交客户标记为 1，非成交客户标记为 0

三、数据准备

由于客户的城市、来源、行业都存在较多的分类，实际在构建 logistic 回归模型时，要求数据分类较少或者用连续型的数据，因此对于分类较多的城市、来源、行业先做数据变化处理，具体采用数据标准化处理。

3.1 数据标准化处理方法

数据的标准化是将数据按比例缩放，使之落入一个小的特定区间。在某些比较和评价的指标处理中经常会用到，去除数据的单位限制，将其转化为无量纲的纯数值，便于不同单位或量级的指标能够进行比较和加权。其中最典型的就是数据的归一化处理，即将数据统一映射到[0,1]区间上，常见的数据归一化 $\min-\max$ 标准化法，也叫离差标准化，是对原始数据的线性变换，使结果落到[0,1]区间，转换函数如下：

$$x^* = \frac{x-\min}{\max-\min}$$

其中 $\max$ 为样本数据的最大值， $\min$ 为样本数据的最小值，x 为原数据，x^* 对应 x 经归一化处理后的值。

3.2 数据处理

对于城市：首先统计汇总所有城市的已联系客户量、已成交客户量，计算城市已联系成交率并排序得到已联系成交率最高及最低的城市，分别赋予 $\max_{城市}$ 和 $\min_{城市}$ 值，计算其他城市 $x_{城市}$ 归一化变换后的值 $x_{城市}{}^*$，得到每个城市经变换后的值，通过关联匹配即可为数据库中的每家客户对应打上城市得分数据，对应的城市联系成交率为 0 或者无城市信息的客户赋得分值为 0。

对于行业：同样的，首先汇总所有行业的已联系客户量、已成交客户量，计算行业已联系成交率并排序得到已联系成交率最高及最低的行业，分别赋予 $\max_{行业}$ 和 $\min_{行业}$ 值，计算其他行业 $x_{行业}$ 归一化变换后的值 $x_{行业}^{*}$，得到每个行业经变换后的值，数据库中一家客户可能对应多个行业，对多个行业对应的得分进行汇总求和即得到该客户最终的行业得分，对数据库中所有客户采用相同的方法即得到变换后的所有客户的行业得分数据，对应的行业联系成交率为 0 或者无行业信息的客户赋得分值为 0。

对于来源：同样的，首先汇总所有来源的已联系客户量、已成交客户量，计算来源已联系成交率并排序得到已联系成交率最高及最低的来源，分别赋予 $\max_{来源}$ 和 $\min_{来源}$ 值，计算其他行业 $x_{来源}$ 归一化变换后的值 $x_{来源}^{*}$，得到每个来源经变换后的值，数据库中一家客户可能对应多个来源，对多个来源对应的得分进行汇总求和即得到该客户最终的来源得分，对数据库中所有客户采用相同的方法即得到变换后的所有客户的来源得分数据，对应的来源联系成交率为 0 或者无来源信息的客户赋得分值为 0。

附件：各城市、行业、来源联系成交率得分

各城市、行业、来源联系成交率得分.

对于最近一次联系时长间隔：考虑到临时数据库更新最后时间为 2013-4-28，所以选取 2013-4-28 为计算联系时长间隔的最后节点，计算客户最后一次联系时间与该时间的时长间隔，无有效联系时间的赋极值 9999。

对于最近一次来源时长间隔：同样选取 2013-4-28 为来源创建时间的最后节点，计算客户最后一次来源创建时间与该时间的时长间隔，无来源创建时间的赋极值 9999。

对于其他数据字段，根据数据字段选取时的定义说明从数据库提取数据并进行相应的处理得到最终的建模数据，如下图所示：

	客户编号	分配状态	城市得分	行业得分	来源得分	有效联系次数	最近联系时长间隔	来源次数	最近来源时长间隔	网站咨询次数	国外合作次数	被分配次数	灭失销售进程	是否外贸新客户	是否成交
1	2154095	1	0.10560...	0.511649...	0	22	16	0	9999	0	0	4	0	0	0
2	2154115	0	0.15214...	0.050206...	0.2828...	3	493	6	130	0	0	3	0	0	0
3	2154121	0	0.15214...	1	0.1698...	3	1061	2	331	0	0	3	0	0	0
4	2154164	0	0	0.008460...	0	1	2071	0	9999	0	0	1	0	0	0
5	2154167	0	0.15438...	0.008460...	0	1	1795	0	9999	0	0	1	0	0	0
6	2154198	0	0.05989...	0.135566...	0	1	1696	0	9999	0	0	2	0	0	0
7	2154215	0	0.33892...	0.008460...	0	1	2071	0	9999	0	0	1	0	0	0
8	2154230	0	0.05989...	0.135898...	0	1	1696	0	9999	0	0	2	0	0	0
9	2154313	0	0.08344...	0.249333...	0	1	2356	0	9999	0	0	1	0	0	0
10	2154356	1	0.15214...	0.159728...	0.7295...	44	9	9	148	0	2	2	1	1	1
11	2154381	1	0.07738...	0.465670...	0.5381...	18	166	9	130	0	0	7	1	0	0
12	2154416	0	0.06464...	0.214294...	0.5638...	1	1734	9	18	0	0	2	0	1	0
13	2154439	0	0.33892...	0.091073...	0.0238...	1	1745	1	998	0	0	1	0	0	0
14	2154456	0	0.11984...	0.123298...	0.0238...	1	2418	1	994	0	0	1	0	0	0

图 3.1 logistic 建模数据

四、建立模型

4.1 分析软件选取

本次客户识别选择了“数据挖掘软件 clementine 12.0”。Clementine 作为数据挖掘工具平台之一，相比较其他数据挖掘工具，clementine 采用流结构构建模型，条理清晰，易于理解。

4.2 建模过程描述

利用数据挖掘软件 clementine 12.0 建立如下的模型流文件：

图 4.1 logistic 模型流文件

（1）读取数据：首先，通过 clementine 中的“数据库导入”节点，导入经数据整理后存放于数据库的建模数据；

（2）筛选字段：1、虽然在数据字段选取时共选取了 20 个字段，去除用于标记客户的“客户编号”和标记客户是否成交的“是否成交”字段，剩余 18 个字段。考虑到“客户等级”与“客户状态”需结合考虑，故将两字段进行合并，

这样就从原先的 4 个分类的客户等级变成 12 个分类。纳入“字段重要性评估”发现分类太多，字段重要性不明显，不得不将“客户等级”、“客户状态”字段剔除，以保证模型有更好的结果；2、实际成交客户绝大多数为“已分配”，从模型试运行得到的结果中也发现预测为成交的客户都为已分配，“分配状态”实际上过度决定了是否成交，为了避免这种影响，不将“分配状态”纳入模型，另一方面也能识别出倾向于成交而未分配的客户；3、在多次模型运行结果中，2010 年-2012 年外贸出口金额对是否成交影响较小，甚至不在影响因素范围内，可直接剔除数据，只考虑已代表外贸数据情况的“是否外贸数据”字段；最终，纳入模型的共有 13 个字段，其中“是否成交”为输出变量，用于标记实际成交情况。

（3）数据选择：在首次运行模型时，将所有数据都纳入计算，得到模型预测成交的准确率只有 26%，由于未成交客户数量过多而成交客户太少导致过度预测不成交的准确率，这对于识别客户没有多大用处。为进一步提高模型预测成交的准确率，需适当降低未成交客户数量，因此将所有已成交客户及抽样未成交客户合并后的数据纳入模型。多次运行模型测试后，随机抽取约 35000 家未成交客户与 3535 家已成交客户得到最多的变量数（12 个变量中的 11 个）及较好的预测成交准确率（87.6%，具体见模型评估部分）。

（4）数据分区：将数据分为训练集和测试集，在训练集得到模型结果后，用训练集数据验证模型是否有相同的准确率，以及其他方面的评估。

（5）建立模型：通过“logistic 回归”模型节点，选用“前进法”作为建模方法，并对模型节点包括运行停止条件、判别条件等设置后，运行模型流得到相应的模型结果。

（6）结果评估：对模型准确率、性能进行评估以检查模型是否适用。

（7）导出结果：导出模型结果到数据库，用于进一步计算客户成交率及评估模型性能等。

4.3 模型结果

对 12 个字段纳入模型后，得到各系数及显著性结果如表：

表 4.1 模型系数及显著性

字段	系数	显著性
常数	-1.4508	0
城市得分	2.875061	0.003
行业得分	0.504914	0
来源得分	1.218699	0
有效联系次数	0.118218	0
最近联系时长间隔	-0.0019	0
最近来源时长间隔	6.31E-05	0
网络咨询次数	0.848363	0
国外会刊次数	0.16641	0.004
被分配次数	-0.52596	0
灭失销售进程	0.210496	0.042
是否外贸数据客户（1）	-0.44089	0
来源次数	1.089	0.297

注：1、显著性<=0.05 时，系数才能选用，否则应丢弃，“来源次数”未通过显著性检验，故系数未进入模型；

2、“是否外贸数据客户（1）”表示有外贸数据来源的客户，带入模型计算时应转换为 1-是否外贸数据客户；

3、由于不同时期客户各项数据不同，模型系数也会随着建立的时间不同而发生改变，各项系数并不唯一；

4、从各系数的正负号也可以大致看出各因素与成交的正负关联情况。

到这一步实际上求出了代表各变量系数的$\beta_0,\beta_1,\cdots,\beta_k$的值，根据

$$P=\frac{\exp(\alpha)}{1+\exp(\alpha)}, \quad \alpha=\beta_0+\beta_1 x_1+\cdots+\beta_k x_k$$

得到对应的每一家客户的成交概率 P，由 $P\geq 0.5$ 判断客户是否倾向于成交，达到预测是否成交的目的（$L-是否成交字段标记为 1，则预测为成交，0 预测为不成交）。结果如图所示：

客户编号	城市得分	行业得分	来源得分	有效联系次数	最近联系时长间隔	最近来源时长间隔	网络咨询次数	国外会刊次数	被分配次数	灭失销售进程	是否外贸数据客户	是否成交	P	$L-是否成交
8692	0.1537...	0.5116...	1.0793...	161	61	8	0	2	1	8	1	1	0.999999...	1
2145301	0.0581...	0.2493...	0.8221...	173	20	3	0	5	1	4	0	1	0.999999...	1
2995	0.2569...	0.8864...	2.0600...	125	3	0	2	13	1	3	1	1	0.999999...	1
2416229	0.2569...	0.7622...	0.3813...	149	5	234	3	8	1	3	1	1	0.999999...	1
5620	0.5296...	0.8864...	1.2489...	155	17	279	0	1	1	4	1	1	0.999999...	1
2703899	0.2569...	0.8590...	1.0569...	161	6	6	0	3	1	5	0	1	0.999999...	1
2055697	0.2962...	0.2727...	0.9221...	154	26	9	0	5	1	7	1	1	0.999999...	1
2769215	0.0539...	1.7622...	0.7899...	155	3	8	0	3	1	10	0	1	0.999999...	1
374	0.5296...	0.9437...	1.9688...	140	0	29	0	1	1	5	1	1	0.999999...	1
9524	0.5296...	1.0456...	1.0624...	129	6	5	4	8	1	1	1	1	0.999999...	1
3275716	0.2860...	1	1.4117...	115	33	9	1	6	1	17	1	1	0.999999...	1
4546551	0.1144...	0.7963...	0.2156...	170	70	115	0	3	1	4	0	1	0.999999...	1
6596	0.5296...	1.3556...	0.9121...	147	12	52	0	8	1	6	1	1	0.999999...	1
2576832	0.2195...	0.2493...	0.8420...	157	20	9	0	5	1	3	1	1	0.999999...	1
3082962	0.0773...	1.2738...	0.8880...	150	19	24	1	2	1	3	1	1	0.999999...	1
2369954	0.2860...	0.0224...	0.6851...	151	4	9	0	2	1	7	1	1	0.999999...	1
2404918	0.2569...	0.8864...	1.7017...	138	3	29	0	3	1	7	1	0	0.999999...	1

图 4.2 成交概率 P 及预测结果

五、模型评估

5.1 模型准确率

通过在 clementine 中对模型结果进行评估,可以得到如下的模型准确率结果:

输出字段 是否成交 的结果

比较 $L-是否成交 与 是否成交

'分区'	1_训练		2_测试	
正确	26,424	98.38%	11,492	98.43%
错误	436	1.62%	183	1.57%
总计	26,860		11,675	

图 5.1 模型评估

训练集模型整体预测准确率为 98.38%,模型预测准确率较高。运用分区的测试集数据做进一步的检验，得到模型的准确率为 98.43%，测试集同训练集有相同的结果，模型预测结果较为稳定。进一步查看模型具体的分类结果，如下表：

表 5.1 模型分类预测结果

实际值 \ 预测值		是否成交		百分比
		0	1	
是否成交	0	24282	162	99.3%
	1	300	2116	87.6%
总百分比				97.6%

虽然对不成交的客户预测准确率较高，但实际我们最希望得到的结果为实际成交预测也为成交的这部分结果，实际有 87.6%的预测准确率，同样有较高的预测准确率。

5.2 模型效果评估

以测试集预测结果进行评估，筛选出所有测试集数据，并由已知的是否成交、模型计算得到成交概率 P，按成交概率 P 的百分位数统计不同百分位数下的实际成交与不成交量，并进一步计算对应的百分位数下的累计覆盖、累计命中、累计提升、累计捕获。如图所示(具体可见附件计算)：

	A	B	C	D	E	F	G	H
1	P（百分位数统	实际成交		总计	累计覆盖	累计命中	累计提升	累计捕获
2		1	0					
3	1	451	288	739	0.007811	0.610284	51.78111	0.404484
4	0.99	109	201	310	0.011088	0.533842	45.29516	0.502242
5	0.98	49	154	203	0.013234	0.486422	41.27168	0.546188
6	0.97	37	129	166	0.014989	0.455571	38.6541	0.579372
7	0.96	24	92	116	0.016215	0.436767	37.05857	0.600897
8	0.95	34	118	152	0.017821	0.417556	35.42863	0.63139
9	0.94	17	86	103	0.01891	0.403018	34.19512	0.646637
10	0.93	18	83	101	0.019978	0.391005	33.17583	0.66278
11	0.92	15	92	107	0.021109	0.377566	32.03557	0.676233
12	0.91	16	100	116	0.022335	0.364411	30.91936	0.690583
13	0.9	9	75	84	0.023223	0.354574	30.08476	0.698655
14	0.89	8	82	90	0.024174	0.344119	29.19764	0.70583
15	0.88	8	79	87	0.025094	0.334878	28.41356	0.713004
16	0.87	7	77	84	0.025982	0.326282	27.68418	0.719283
17	0.86	9	65	74	0.026764	0.3203	27.17668	0.727354
18	0.85	6	65	71	0.027514	0.313869	26.63098	0.732735
19	0.84	4	65	69	0.028244	0.30726	26.07029	0.736323
20	0.83	2	60	62	0.028899	0.301024	25.54116	0.738117

图 5.2 成交概率 P 百分位数下累计覆盖、命中、提升、捕获情况

注：1、累计覆盖率=前 N 个百分位数下的总客户数/全部百分比下的客户数总和；

2、累计命中率=前 N 个百分位数下的实际总成交客户数/前 N 个百分位数下的总客户数；

所以，平均命中率=实际全部成交客户数/总客户数；

3、累计提升率=前 N 个百分位数下累计命中率/平均命中率；

4、累计捕获率=前 N 个百分位数下的实际总成交客户数/全部百分比下的实际成交客户总和；

附件：logistic 效果评估

logistic效果评估.xls

5.2.1 累计命中率

从下图可以看出，随着覆盖范围的增大，累计命中率先急剧下降后逐渐趋于平缓，如预测范围累计覆盖前 2%的客户时，有 66%的用户实际也为成交客户；而预测范围累计覆盖前 5%的客户时，只有 20%的用户实际也为成交客户。虽然随着覆盖范围的增大覆盖了更多的成交客户，但同时覆盖了更多的非成交客户，从而导致命中率反而下降了。

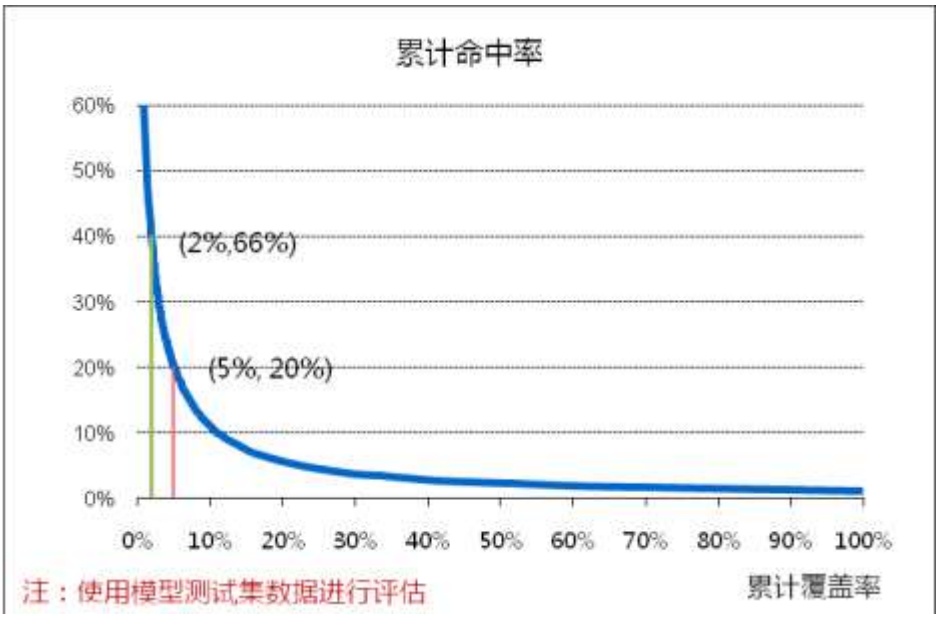

图 5.3 累计命中率

5.2.2 累计提升度

从下图可以看出，较高的提升度集中在较小的覆盖范围内，即运用模型能在较小的覆盖范围内达到更高的目标客户识别率，如预测范围覆盖在 2%的客户时，对比平均成交率能达到约 33 倍的提升；而预测范围覆盖在 5%的客户时，对比平均成交率能达到约 20 倍的提升，即运用模型识别到目标客户的概率是随机分配到目标客户的 20 倍。

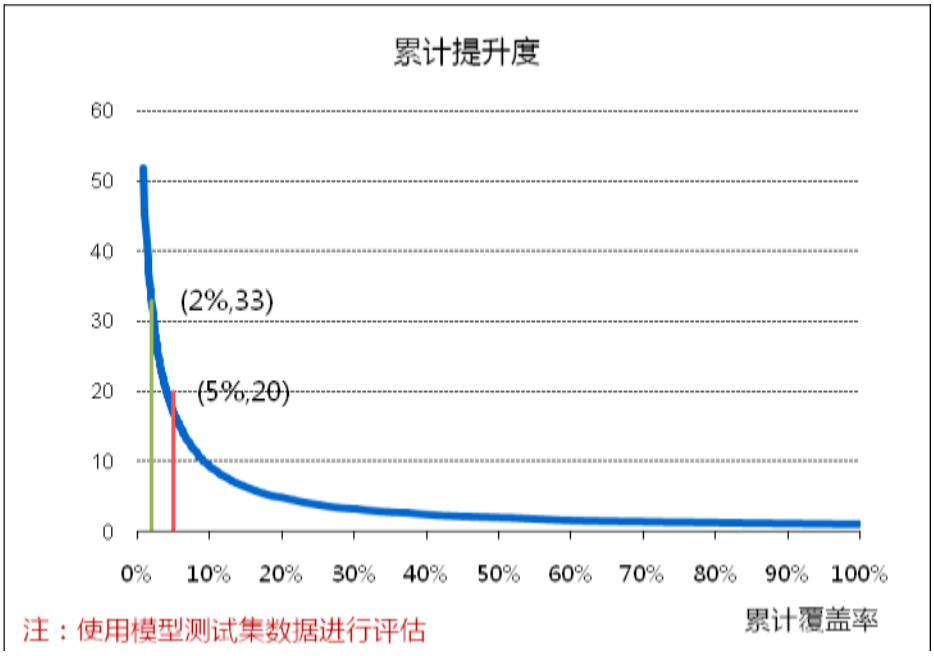

图 5.4 累计提升度

5.2.3 累计捕获率

从下图可以看出，捕获率曲线随着累计覆盖范围的增大，先陡峭上升而后趋于平稳上升，说明利用模型预测时，大部分成交客户能在较小样本范围内被成功预测命中，如预测范围覆盖样本的 5%时，模型成功预测命中了 85%的成交客户，广撒渔网式的粗放选择并非代表着较高的效益，有针对性的目标客户甄选才能有效的在既定成本下达到效益的最大化。

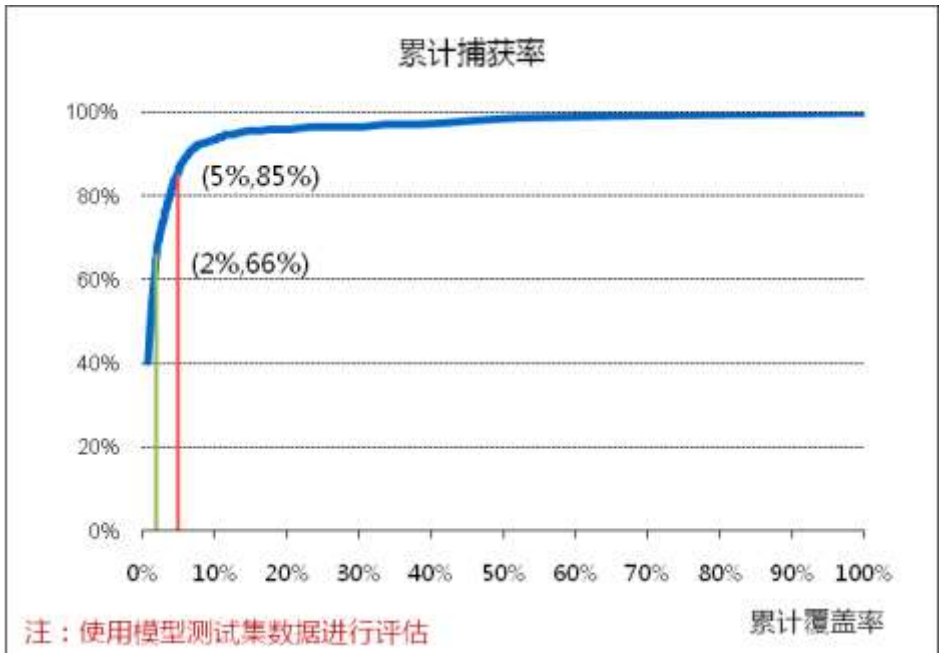

图 5.5 累计捕获率

综上，使用模型在预测是否成交客户时有优于随机挑选客户的结果，模型在用于预测成交客户上有较好的性能。

六、模型使用

选取预测结果为成交且实际不为成交的客户得到附件如下，得到的客户即为本次识别的目标客户，也可如同模型评估部分，在确定覆盖比例后，选择合适的前 X%的成交率较高的客户作为样本数据。logistic 模型的预测准确情况，还需在实际的运用中进行进一步的跟进检验。

附件：logistic 模型目标客户

logistic模型目标客户.xls